GenomeXplore

Plateforme d'exploration et de sélection des génomes de référence et de sélection de données brutes associées

Julien FOURET julien.fouret@cnrs.fr et Carine REY carine.rey@ens-lyon.fr

1. Contexte

Ce project est proposé par l'équipe Bioinformatique et Biostatistique du Centre International de Recherche en Infectiologie (CNRS UMR5308 - INSERM U1111 - UCBL1 - ENSL).

Les projets de génomique comparative — par exemple l'étude de l'évolution des facteurs de restriction viraux (OAS, PKR, APOBEC, TRIM, Mx…) chez les cordées — exigent des génomes bien assemblés et bien annotés. L'analyse des séquences régulatrices (conservation de motifs dans les UTR) n'a de sens que si les UTR sont correctement annotés. Il est essentiel de disposer d'outils efficace pour sélectionner les génomes à intégrer dans une étude de génomique comparative. Il serait également ensuite très utile de pouvoir associer aux génomes des données brutes représentatives : RNA-seq en premier lieu, mais aussi ChIP-seq ou Hi-C pour réévaluer la qualité des annotations.

Ces ressources sont dispersées entre **NCBI** (États-Unis), **Ensembl** (Europe) et **NGDC/GWH** (Chine), avec des formats, des nomenclatures et des niveaux de qualité hétérogènes. Les métadonnées des données de séquence sont en texte libre, bruitées. Une sélection manuelle est lente et peu reproductible.

2. Objectif

Une **application web facilement déployable localement** (Streamlit, Flask, ou FastAPI + Vue ; installation par `uv install` ou conteneur unique) qui :

1. **collecte** les références de génomes, annotations et statistiques de qualité disponibles dans les trois sources, à partir d'une **recherche taxonomique** ;
2. permet de **filtrer et sélectionner** des génomes (par référence) sur critères de qualité, avec détection d'outliers ;
3. **identifie les jeux de données brutes disponibles** pour les espèces retenues et sélectionne un échantillon représentatif ;
4. **exporte le tout en JSON** : URLs des artefacts + accessions retenues, consommable par des workflows.

Deux contraintes permanentes :

- Ne jamais télécharger d'artefacts lourds (FASTA, GFF, reads) ; uniquement fichiers de stats et métadonnées (ex. JSON du NCBI `datasets` tool, rapports d'assemblage, réponses d'API)
- Inventorier dans le JSON les **URLs de tous les artefacts utiles** par type (génome, annotation, transcrits, protéines…), sans les télécharger.

  Dans un premier temps il serait pertinent de se focaliser uniquement sur les *metazoa*.

3. Organisation du travail : modules

Trois **modules**. Estimation : M1 ≈ 40 %, M2 ≈ 25 %, M3 ≈ 35 % du temps.

4. Module 1 — Compréhension et Data mining des sources

M1a — Étude de la structuration interne des bases de données (part considérable du projet)

Pour chaque source, produire une **fiche documentaire** factuelle :

- **Organisation interne** : arborescences de fichiers (ex. structure `refseq/vertebrate_mammalian/<taxid>/` de NCBI), conventions de nommage, emplacement des rapports, GFF/GTF, fichiers de stats.
- **Pipelines internes** : comment assemblages et annotations sont produits et mis à jour (annotation releases RefSeq, cycles de release Ensembl, pipeline de soumission GWH).

- **Versionnement des artefacts** : versions d'assemblage GCA/GCF, numéros d'annotation release, versions WGS.
- **Stockage et accès aux archives** : FTP/HTTPS, Aspera, miroirs ; points d'entrée API (EUtils, `datasets` CLI, REST Ensembl, BioMart, ENA Portal API, API NGDC).

  Sur ce point spécifique les étudiants pourront s'appuyer sur l'expertise des encadrants du service BIBS.

Livrable : trois fiches sources + glossaire commun. Cette documentation pilote directement le collecteur : c'est elle qui détermine où récupérer chaque type de fichier.

M1b — Data mining

- **Entrée : recherche taxonomique** (nom scientifique ou taxid, navigation dans l'arbre). Sortie : liste des génomes du taxon et de ses descendants.
- Par génome : accession, source, taxid, niveau d'assemblage, statistiques disponibles (N50, BUSCO si publié, nombre de gènes/transcrits, exons, part d'UTR annotés) — à partir des seuls petits fichiers (rapports, JSON, réponses d'API).
- **Inventaire des URLs par type d'artefact** : génome FASTA, annotation GFF/GTF, CDS, cDNA, protéines, preuves RNA, rapport BUSCO. Le JSON fournit les liens, pas les données.
- **Sortie :** base locale normalisée (SQLite/DuckDB) + JSON par génome.

Points d'attention : doublons entre bases, synonymes d'espèces, rate limits, cadence de mise à jour.

5. Module 2 — Sélection des génomes

- **Filtrage interactif** : niveau d'assemblage, seuils (N50, BUSCO, nombre de gènes, % de gènes avec UTR annotés — critère prérequis pour l'analyse des motifs régulateurs).
- **Statistiques descriptives par clade** pour établir des plages plausibles.
- **Détection d'outliers** : z-score, MAD (robuste, tailles en log) ; optionnellement multivarié (Mahalanobis, Isolation Forest) pour des combinaisons de métriques (ex. grand assemblage, peu de gènes).
- **Livrable :** interface de filtrage, rapport d'outliers, set sélectionné.

6. Module 3 — Recherche de données brutes (répétable)

- **Paramétrable par type de données** : RNA-seq (exemple par défaut), ChIP-seq, Hi-C, … Interrogation de SRA, ENA, GSA via API de métadonnées.
- Récupération des métadonnées : tissu, condition, layout, plateforme, profondeur ; normalisation minimale du texte libre.
- **Critères de sélection :** type de données, qualité minimale des métadonnées, **plafond de 10 runs par espèce**.
- **Processus de sampling robuste :** sélection par **embeddings des descriptions textuelles** (sentence-transformers), puis sélection *farthest-first* ou k-medoids sur distances cosinus pour couvrir la diversité tissulaire et expérimentale. Approche par règles acceptée en repli ; l'approche par embeddings est le cœur méthodologique attendu.
- **Réutilisabilité :** pour une même sélection sauvegardée, plusieurs passes de M3 (une par type de données), fusionnées dans l'export.

7. Fonctionnalités transverses

- **Sauvegarde des sélections** : chaque sélection (module 2 + passes module 3) est persistée localement (nom, date, critères, contenu) pour y revenir.
- **Import de statistiques complémentaires** : les pipelines produisant des stats additionnelles (qualité de mapping, couverture, BUSCO recalculé…) sont **hors périmètre**, mais leur **réintégration est dans le périmètre** : format d'import JSON/CSV rattaché à une sélection, affichage à côté des stats natives, inclusion dans la détection d'outliers.
- **Exports** : JSON par espèce — URLs par type d'artefact, accessions retenues, méthode de sélection. Format versionné et auto-descriptif.